

Diseño de encuestas

Del cuestionario a la tabla de datos

Objetivo del bloque

Al terminar, cada pregunta que se escriba en un cuestionario debería poder responder tres cosas:

1. Qué columna genera en la tabla de datos.
2. De qué tipo es esa columna.
3. Cómo se codifican las respuestas y los faltantes.

No se discute el objeto de estudio ni el marco teórico. Solo el armado.

La regla que organiza todo

Diseñar la tabla antes que el formulario.

- Filas: una por respondente.
- Columnas: una por variable.

Si no se puede dibujar la columna que produce una pregunta, la pregunta no va.

Ejemplo de trabajo

Encuesta de gasto mensual a estudiantes universitarios. Once preguntas en tres bloques:

A. Perfil 1. ¿En qué año de la carrera está? 2. ¿Vive en la casa familiar? 3. ¿Cuánto paga de alquiler por mes? 4. ¿Trabaja actualmente?

B. Gastos en los últimos 30 días 5. ¿Cuánto gastó en comida fuera de casa? 6. ¿Cuánto gastó en transporte? 7. ¿En cuáles de estos rubros tuvo algún gasto? (marque todas) 8. ¿Lleva registro de sus gastos?

C. Ingresos y percepción 9. ¿Cuál es su principal fuente de ingresos? 10. ¿Cómo describiría su situación económica? 11. ¿Qué gasto le resulta más difícil de controlar?

Antes de seguir: ¿cuántas columnas tiene la tabla resultante?

Fundamentos

Una pregunta es una medición

Operacionalización: el camino desde lo que se quiere saber hasta la columna.

concepto → dimensión → indicador → pregunta → variable

En el ejemplo:

Concepto	Dimensión	Indicador	Pregunta	Variable
Situación económica	Percepción subjetiva	Autoevaluación 1-5	P10	situacion
Situación económica	Gasto efectivo	Monto en comida, 30 días	P5	gasto_comida
Situación económica	Gasto efectivo	Monto en transporte, 30 días	P6	gasto_transporte

Un concepto suele necesitar varias columnas. Una columna nunca es el concepto: es un indicador de una de sus dimensiones.

“Diseñar la tabla antes que el formulario” es esto: decidir qué indicadores se necesitan antes de escribir cómo se preguntan.

Niveles de medición

Stevens (1946) distingue cuatro niveles según qué operaciones tienen sentido sobre los valores:

Nivel	Qué se puede hacer	Ejemplo	En la tabla
Nominal	Distinguir categorías	fuentes de ingresos	fuentes_ingreso
Ordinal	Ordenarlas	año de carrera, escala 1-5	año, situación
Intervalo	Medir distancias; el cero es convencional	temperatura en °C	(no hay en el ejemplo)
Razón	Distancias y cocientes; el cero es real	pesos gastados	gasto_comida

- Cada nivel permite lo del anterior y algo más.
- El diseño de la pregunta fija el nivel. Después no se puede subir: de tramos no se recupera el monto.
- Sí se puede bajar: de gasto_comida se construyen tramos cuando haga falta.
- Promediar una escala 1-5 es tratar una ordinal como de intervalo. Se hace con frecuencia; lo que no se hace es sin declararlo.

Validez y confiabilidad

Dos propiedades de una pregunta como instrumento de medición:

- **Validez:** mide lo que dice medir. *¿Está conforme con lo que gasta en comida y en transporte?* no mide ninguna de las dos cosas por separado.
- **Confiabilidad:** mide lo mismo cada vez que se aplica. *¿Cuánto gasta en transporte?* sin período de referencia recibe respuestas distintas de la misma persona según el día.

La sección de redacción que sigue es una lista de formas conocidas de perder validez o confiabilidad.

Fuentes de error

Marco de error total de encuesta (Groves et al. 2009). Cuatro fuentes, en el orden en que aparecen:

Fuente	Qué es	Dónde se controla
Cobertura	La lista de la que se saca la muestra no contiene a toda la población	Marco muestral
Muestreo	Se observa una parte, no el todo	Diseño muestral
No respuesta	Personas seleccionadas que no contestan, o ítems que quedan en blanco	Longitud, orden, redacción
Medición	La respuesta registrada no coincide con el valor verdadero	Redacción, opciones, escalas

Este bloque trabaja sobre las dos últimas. Cobertura y muestreo quedan para otra clase.

Unidades

- **Población:** a quién se quiere describir.
- **Unidad de análisis:** sobre qué se hacen afirmaciones (una fila de la tabla).
- **Unidad de respuesta:** quién contesta el cuestionario.

En el ejemplo las tres coinciden: estudiantes de la facultad, un estudiante por fila, contesta el propio estudiante.

No siempre es así. En una encuesta de gasto de hogares la unidad de análisis es el hogar y responde un informante; en una encuesta a empresas responde una persona por la organización. Cuando no coinciden, el cuestionario tiene que decir explícitamente por quién se está respondiendo.

Tipos de pregunta y variable que generan

Opción única, sin orden

| P9. ¿Cuál es su principal fuente de ingresos? ☐ Familia ☐ Trabajo ☐ Beca ☐ Ahorros ☐ Otro

- Una columna.
- Variable **categorica nominal**: las categorías no se ordenan.
- Se guarda como texto o como código numérico con etiqueta.

Opción única, con orden

| P1. ¿En qué año de la carrera está? ☐ 1.º ☐ 2.º ☐ 3.º ☐ 4.º ☐ 5.º o más

- Una columna.
- Variable **ordinal**: hay orden, pero la distancia entre categorías no está definida.
- El orden debe quedar registrado explícitamente (no se infiere del texto).

Sí / No

| P2. ¿Vive en la casa familiar? ☐ Sí ☐ No

- Una columna.
- Variable **binaria**. Es una nominal de dos categorías; conviene almacenarla como lógica (TRUE/FALSE) o como 0/1.

Escala de valoración

| P10. ¿Cómo describiría su situación económica en los últimos 30 días? 1 Muy ajustada · 2 · 3 · 4 · 5 Muy holgada

- Una columna.
- Variable **ordinal**. Que los valores sean números no la vuelve cuantitativa.
- Tratarla como numérica (promediar, por ejemplo) es una decisión analítica que se toma después y se declara. No es una propiedad del dato.

Numérica directa

| P5. ¿Cuánto gastó en comida fuera de casa en los últimos 30 días? \$ ____

- Una columna.
- Variable **cuantitativa** (continua; sería discreta para una cantidad de veces).
- Es la que más información conserva. El costo: preguntas difíciles de recordar o sensibles bajan la tasa de respuesta.

Numérica por tramos

| P6. ¿Cuánto gastó en transporte en los últimos 30 días? ☐ Nada ☐ Hasta \$1.000 ☐ \$1.001 a \$3.000 ☐ \$3.001 a \$6.000 ☐ Más de \$6.000

- Una columna, **ordinal**.
- Se pierde la posibilidad de calcular promedios o de recortar tramos distintos después.
- Se gana tasa de respuesta. Es un intercambio que se decide antes de salir a campo, porque no se puede deshacer.

P5 y P6 preguntan lo mismo (un monto) con dos diseños distintos. Ninguno es correcto en general.

Selección múltiple

P7. ¿En cuáles de estos rubros tuvo algún gasto en los últimos 30 días? ☐ Materiales de estudio ☐ Salidas ☐ Ropa ☐ Suscripciones digitales ☐ Salud

No genera una variable. Genera una columna binaria por opción:

id	rubro_materiales	rubro_salidas	rubro_ropa	rubro_suscripciones	rubro_salud
1	1	1	0	1	0
2	0	1	1	1	0

Guardar la respuesta como un solo texto ("Salidas; Ropa; Suscripciones") es el error más frecuente en encuestas armadas sin pensar la tabla.

Pregunta abierta

| P11. ¿Qué gasto le resulta más difícil de controlar? _____

- Una columna de **texto**.
- No se analiza directamente: requiere codificación posterior (leer, agrupar, asignar categorías). Es la pregunta más cara de procesar.
- Se justifica cuando no se conocen las categorías de antemano o cuando se quiere el lenguaje del respondente.

Resumen

Formato de pregunta	Columnas	Tipo de variable	En el ejemplo
Opción única sin orden	1	Nominal	P9
Opción única con orden	1	Ordinal	P1, P4, P8
Sí / No	1	Binaria	P2
Escala 1-5	1	Ordinal	P10
Número	1	Cuantitativa	P3, P5
Tramos	1	Ordinal	P6
Selección múltiple con k opciones	k	Binarias	P7
Abierta	1	Texto (a codificar)	P11

Once preguntas, diecisiete columnas.

Redacción de preguntas

Una idea por pregunta

| ¿Cree que la comida de la facultad es cara y de mala calidad?

Dos preguntas en una. Quien la considera cara pero de buena calidad no tiene respuesta.

Cada pregunta mide una sola cosa. Si aparece una “y”, revisar.

Lenguaje neutro

| ¿No cree que debería ahorrar más?

Induce la respuesta y contiene una negación (responder “no” es ambiguo).

Formulación neutra: *¿Lleva registro de sus gastos?* o *¿Cómo describiría su situación económica?*

Período de referencia explícito

| ¿Cuánto gasta en transporte?

¿Por semana, por mes, en un mes típico, en el último mes? Cada persona responderá algo distinto.

¿Cuánto gastó en transporte en los últimos 30 días?

“Los últimos 30 días” y “un mes típico” no son equivalentes: uno pide recordar, el otro pide estimar. Se elige uno y se sostiene en todo el cuestionario.

Categorías exhaustivas y excluyentes

Alquiler mensual: ☐ Hasta \$8.000 ☐ \$8.000 a \$12.000 ☐ \$12.000 a \$20.000

- No excluyentes: 8.000 y 12.000 caen en dos tramos.
- No exhaustivas: más de 20.000 no tiene opción.

Toda respuesta posible debe tener exactamente una casilla.

Selección múltiple disfrazada

| ¿De dónde recibe ingresos? ☐ Familia ☐ Trabajo ☐ Ambos ☐ Otro

“Ambos” delata que la pregunta admite más de una respuesta. Hay dos salidas:

- Selección múltiple: una columna binaria por fuente.
- Opción única con la palabra *principal*: *¿Cuál es su principal fuente de ingresos?* (es lo que hace P9).

Opciones de respuesta

Escalas

- **Cantidad de puntos:** 4 obliga a tomar posición; 5 permite un punto neutro. Ninguna es correcta en general; se decide y se mantiene igual en todo el cuestionario.
- **Etiquetas:** etiquetar solo los extremos (1 = Muy ajustada, 5 = Muy holgada) o todos los puntos. Etiquetar todos reduce interpretaciones distintas.
- **Dirección:** mantener siempre el mismo sentido (mayor valor = mejor situación) para no confundir al respondente ni al analista.

“Otro (especifique)” y “No sabe / No contesta”

- **Otro (especifique)** genera dos columnas: la categoría otro en fuente_ingreso y un campo de texto fuente_otro. Si muchas respuestas caen en “Otro”, faltó una categoría.
- **No sabe / No contesta** es una decisión de diseño. Si se ofrece, hay que definir cómo se codifica y distinguirla de la no respuesta (dejar en blanco).

Orden, filtros y longitud

Orden

- De lo general a lo específico.
- Preguntas sensibles (montos de ingreso, situación económica) al final: si la persona abandona, ya respondió el resto.
- Las primeras preguntas deben ser fáciles y claramente relacionadas con el tema anunciado.

En el ejemplo: el perfil va primero, los montos de gasto en el medio, ingresos y percepción al final.

Preguntas filtro

| P2. ¿Vive en la casa familiar? ☐ Sí ☐ No → si Sí, pasar a P4 P3. ¿Cuánto paga de alquiler por mes? \$ ____

Quien responde “Sí” en P2 no tiene P3. Esa celda queda vacía **por diseño**.

Son **faltantes estructurales**. No son lo mismo que la **no respuesta** (la persona debía contestar y no lo hizo). El libro de códigos debe distinguirlos.

Longitud

Cada pregunta tiene un costo: tiempo del respondente y tasa de abandono.

Criterio para conservar una pregunta: la columna que genera se usa en algún análisis previsto. Si no se sabe para qué se va a usar, se elimina.

Libro de códigos

Qué es

El diccionario de variables se escribe **antes** de salir a campo, no después. Es el mismo diccionario del Práctico A y lo que SPSS guarda como metadatos.

Variable	Etiqueta	Tipo	Valores	Faltante
id	Identificador	entero	1, 2, ...	no admite
anio	Año de la carrera	ordinal	1 < 2 < 3 < 4 < 5+	NA
vive_familia	Vive en la casa familiar	binaria	TRUE, FALSE	NA
alquiler	Alquiler mensual (pesos)	cuantitativa	≥ 0	NA si vive_familia = TRUE
trabajo	Situación laboral	ordinal	No < Menos de 20 h < 20 h o más	NA
gasto_comida	Comida fuera de casa, 30 días (pesos)	cuantitativa	≥ 0	NA
gasto_transporte	Transporte, 30 días	ordinal	Nada < Hasta 1.000 < 1.001-3.000 < 3.001-6.000 < Más de 6.000	NA
rubro_* (5)	Tuvo gasto en el rubro	binaria	0, 1	NA
registro	Lleva registro de gastos	ordinal	Nunca < A veces < Siempre	NA
fuentes_ingreso	Principal fuente de ingresos	nominal	Familia, Trabajo, Beca, Ahorros, Otro	NA
fuentes_otro	Otra fuente (texto)	texto	libre	vacío si fuentes_ingreso $\neq$ Otro
situacion	Situación económica, 30 días	ordinal	1 < 2 < 3 < 4 < 5	NA
gasto_dificil	Gasto difícil de controlar (abierto)	texto	libre	vacío

Convenciones de nombres

- Minúsculas, sin espacios ni tildes: `gasto_comida`, no `Gasto en comida`.
- Prefijo común para las binarias de una misma selección múltiple: `rubro_materiales`, `rubro_salidas`, `rubro_ropa`, ...
- El nombre describe el contenido, no la posición: `alquiler`, no `p3`.

Cómo queda la tabla

Lectura y tipos

[pestañas R / Python]

R

```
library(tidyverse)

encuesta <- read_csv("encuesta_gasto.csv")
glimpse(encuesta)
```

```
Rows: 4
Columns: 17
$ id          <dbl> 1, 2, 3, 4
$ anio        <dbl> 2, 4, 1, 3
$ vive_familia <chr> "Sí", "No", "Sí", "No"
$ alquiler    <dbl> NA, 12000, NA, 9000
$ trabajo     <chr> "No", "Sí, 20 h o más", "No", "Sí, menos de 20 h"
$ gasto_comida <dbl> 4500, 8200, NA, 6000
$ gasto_transporte <chr> "1.001 a 3.000", "Más de 6.000", "Hasta 1.000", "Nada"
$ rubro_materiales <dbl> 1, 0, 1, 0
$ rubro_salidas <dbl> 1, 1, 0, 1
$ rubro_ropa    <dbl> 0, 1, 0, 0
$ rubro_suscripciones <dbl> 1, 1, 0, 1
$ rubro_salud   <dbl> 0, 0, 0, 1
$ registro     <chr> "A veces", "Siempre", "Nunca", "A veces"
$ fuente_ingreso <chr> "Familia", "Trabajo", "Familia", "Otro"
$ fuente_otro   <chr> NA, NA, NA, "trabajos freelance"
$ situacion     <dbl> 3, 2, 4, 3
$ gasto_dificil <chr> "salidas", "delivery", NA, "suscripciones"
```

Python

```
import pandas as pd

encuesta = pd.read_csv("encuesta_gasto.csv")
encuesta.dtypes
```

```
id          int64
anio        int64
vive_familia object
alquiler    float64
trabajo     object
gasto_comida float64
gasto_transporte object
rubro_materiales int64
rubro_salidas int64
```

```
rubro_ropa          int64
rubro_suscripciones int64
rubro_salud          int64
registro            object
fuente_ingreso       object
fuente_otro          object
situacion           int64
gasto_dificil        object
dtype: object
```

Tres faltantes de naturaleza distinta: alquiler en los respondentes 1 y 3 (filtro), gasto_comida en el 3 (no respuesta), fuente_otro en 1, 2 y 3 (no aplica). La tabla no los distingue; el libro de códigos sí.

Declarar los tipos

[pestañas R / Python]

R

```
encuesta <- encuesta |>
  mutate(
    anio = factor(anio, levels = 1:5, ordered = TRUE),
    vive_familia = vive_familia == "Sí",
    trabajo = factor(trabajo,
      levels = c("No", "Sí, menos de 20 h", "Sí, 20 h o más"), ordered = TRUE),
    gasto_transporte = factor(gasto_transporte,
      levels = c("Nada", "Hasta 1.000", "1.001 a 3.000",
        "3.001 a 6.000", "Más de 6.000"), ordered = TRUE),
    registro = factor(registro,
      levels = c("Nunca", "A veces", "Siempre"), ordered = TRUE),
    fuente_ingreso = factor(fuente_ingreso),
    situacion = factor(situacion, levels = 1:5, ordered = TRUE)
  )
```

```
$ anio          <ord> 2, 4, 1, 3
$ vive_familia  <lgl> TRUE, FALSE, TRUE, FALSE
$ trabajo       <ord> No, Sí, 20 h o más, No, Sí, menos de 20 h
$ gasto_transporte <ord> 1.001 a 3.000, Más de 6.000, Hasta 1.000, Nada
$ registro      <ord> A veces, Siempre, Nunca, A veces
$ fuente_ingreso <fct> Familia, Trabajo, Familia, Otro
$ situacion     <ord> 3, 2, 4, 3
```

Python

```
encuesta["anio"] = pd.Categorical(encuesta["anio"],
  categories=[1, 2, 3, 4, 5], ordered=True)
encuesta["vive_familia"] = encuesta["vive_familia"] == "Sí"
encuesta["trabajo"] = pd.Categorical(encuesta["trabajo"],
  categories=["No", "Sí, menos de 20 h", "Sí, 20 h o más"], ordered=True)
encuesta["gasto_transporte"] = pd.Categorical(encuesta["gasto_transporte"],
  categories=["Nada", "Hasta 1.000", "1.001 a 3.000",
    "3.001 a 6.000", "Más de 6.000"], ordered=True)
encuesta["registro"] = pd.Categorical(encuesta["registro"],
  categories=["Nunca", "A veces", "Siempre"], ordered=True)
encuesta["fuente_ingreso"] = encuesta["fuente_ingreso"].astype("category")
encuesta["situacion"] = pd.Categorical(encuesta["situacion"],
  categories=[1, 2, 3, 4, 5], ordered=True)
```

```
anio          category
vive_familia  bool
```

trabajo	category
gasto_transporte	category
registro	category
fuentes_ingreso	category
situacion	category

El orden de las categorías se declara en el código porque no está en el archivo. Esa declaración sale del libro de códigos.

Ejercicio

De la tabla al cuestionario

Se quiere obtener esta tabla a partir de una encuesta a clientes de la cafetería de la facultad. Escribir el cuestionario que la produce: texto de cada pregunta, opciones de respuesta, orden y filtros.

Variable	Tipo	Valores	Faltante
id	entero	1, 2, ...	no admite
frecuencia	ordinal	Nunca < 1 a 3 veces < 4 a 8 veces < Más de 8 veces	NA
prod_cafe, prod_comida, prod_frias, prod_otros	binaria (×4)	0, 1	NA si frecuencia = Nunca
atencion	ordinal	1 < 2 < 3 < 4 < 5	NA si frecuencia = Nunca
pago_efectivo, pago_tarjeta, pago_transferencia	binaria (×3)	0, 1	NA si frecuencia = Nunca
estudiante	binaria	TRUE, FALSE	NA
edad	cuantitativa	años	NA
mejora	texto	libre	vacío

Qué se verifica

- Toda pregunta tiene período de referencia.
- Hay un filtro después de `frecuencia` y está indicado a dónde saltar.
- `prod_*` y `pago_*` salen de preguntas de selección múltiple, no de opción única con “ambos”.
- `atencion` tiene los extremos etiquetados y la misma dirección que el resto del cuestionario.
- `edad` está al final.
- Cuántas preguntas se necesitan para producir trece columnas.

Cuestionario de referencia

1. ¿Con qué frecuencia compró en la cafetería en los últimos 30 días? ☐ Nunca ☐ 1 a 3 veces ☐ 4 a 8 veces ☐ Más de 8 veces → si Nunca, pasar a P5
2. ¿Qué productos compró? (marque todas) ☐ Café ☐ Comida ☐ Bebidas frías ☐ Otros
3. ¿Cómo calificaría la atención recibida? 1 Muy mala · 2 · 3 · 4 · 5 Muy buena
4. ¿Con qué medios pagó? (marque todas) ☐ Efectivo ☐ Tarjeta ☐ Transferencia
5. ¿Es estudiante de esta facultad? ☐ Sí ☐ No
6. ¿Qué mejoraría del servicio? _____
7. ¿Cuántos años tiene? ____

Siete preguntas, trece columnas.

Para la bitácora

Seis preguntas con problemas. Para cada una: identificar el problema, reescribirla y decir qué tipo de variable produce (y cuántas columnas).

1. ¿Está conforme con lo que gasta en comida y en transporte?
2. ¿No le parece que gasta demasiado en salidas?
3. ¿Cuánto gastó últimamente en ropa?
4. Gasto en transporte: ☐ \$0 a \$1.000 ☐ \$1.000 a \$3.000 ☐ \$3.000 a \$6.000
5. ¿Cómo paga sus gastos? ☐ Efectivo ☐ Tarjeta ☐ Ambos ☐ Transferencia
6. (Primera pregunta del cuestionario) ¿Cuál es el ingreso mensual exacto de su hogar?

Soluciones

1. Doble cañón. Separar en dos preguntas; cada una ordinal (escala 1-5).
2. Inducida y con negación. *¿Cuánto gastó en salidas en los últimos 30 días?* Cuantitativa, o tramos (ordinal).
3. Sin período de referencia. *¿Cuánto gastó en ropa en los últimos 30 días?* Cuantitativa.
4. Tramos no excluyentes ni exhaustivos. Nada / Hasta 1.000 / 1.001-3.000 / 3.001-6.000 / Más de 6.000. Ordinal.
5. Selección múltiple disfrazada. Una binaria por medio de pago: pago_efectivo, pago_tarjeta, pago_transferencia.
6. Pregunta sensible al inicio y con precisión innecesaria. Mover al final y ofrecer tramos. Ordinal.