



# Diseño de encuestas

---

Del cuestionario a la tabla de datos

## Objetivo del bloque

Al terminar, cada pregunta que se escriba en un cuestionario debería poder responder tres cosas:

1. Qué columna genera en la tabla de datos.
2. De qué tipo es esa columna.
3. Cómo se codifican las respuestas y los faltantes.

No se discute el objeto de estudio ni el marco teórico. Solo el armado.

# La regla que organiza todo

## Diseñar la tabla antes que el formulario.

- Filas: una por respondente.
- Columnas: una por variable.

Si no se puede dibujar la columna que produce una pregunta, la pregunta no va.

## Ejemplo de trabajo

Encuesta de gasto mensual a estudiantes universitarios. Once preguntas en tres bloques:

**A. Perfil** 1. ¿En qué año de la carrera está? 2. ¿Vive en la casa familiar? 3. ¿Cuánto paga de alquiler por mes? 4. ¿Trabaja actualmente?

**B. Gastos en los últimos 30 días** 5. ¿Cuánto gastó en comida fuera de casa? 6. ¿Cuánto gastó en transporte? 7. ¿En cuáles de estos rubros tuvo algún gasto? (marque todas) 8. ¿Lleva registro de sus gastos?

**C. Ingresos y percepción** 9. ¿Cuál es su principal fuente de ingresos? 10. ¿Cómo describiría su situación económica? 11. ¿Qué gasto le resulta más difícil de controlar?

Antes de seguir: ¿cuántas columnas tiene la tabla resultante?

# Fundamentos

---

# De dónde salen los datos sobre personas

Una encuesta es una de varias formas de generar datos. Se distinguen por quién decide qué se registra.

| Fuente                                                                      | Qué se registra                                    | Quién decide qué se registra                            | Qué se obtiene                                                            | Qué se pierde                                                             |
|-----------------------------------------------------------------------------|----------------------------------------------------|---------------------------------------------------------|---------------------------------------------------------------------------|---------------------------------------------------------------------------|
| <b>Preferencias declaradas</b><br>(encuesta)                                | Lo que la persona dice                             | El diseñador del cuestionario                           | Percepciones, intenciones, razones; cualquier cosa que se pueda preguntar | Precisión: memoria, deseabilidad social, no respuesta                     |
| <b>Preferencias reveladas</b><br>(transacciones, registros administrativos) | Lo que la persona hace, inferido de sus elecciones | El sistema que opera la transacción                     | Comportamiento efectivo sin depender de la memoria ni de la honestidad    | El “por qué”; todo lo que el sistema no registra                          |
| <b>Huella digital</b> (logs, clics, ubicación, tiempo en pantalla)          | Comportamiento como subproducto de usar un sistema | Nadie, en el sentido de medición: es un residuo técnico | Volumen y granularidad                                                    | Definición: cada campo hay que reinterpretarlo como si fuera una pregunta |

En el ejemplo, “cuánto gastó en comida fuera de casa” se puede obtener de tres maneras: preguntándolo (P5), leyendo los cobros con tarjeta de estudiante en la cafetería, o leyendo los registros de una app de pedidos. Los tres producen una columna `gasto_comida` que no significa lo mismo.

La idea de preferencia revelada viene de Samuelson (1938): la elección observada informa sobre la preferencia mejor que la declaración. Lo que se pierde es la posibilidad de preguntar por lo que no ocurrió.

## Datos de comportamiento sin preguntas

Cuando el dato no sale de un cuestionario, el libro de códigos igual hace falta. La diferencia es que hay que reconstruirlo:

- **Qué mide cada campo.** Un registro monto en una tabla de cobros: ¿incluye propina? ¿descuentos? ¿en qué moneda?
- **Qué unidad de análisis tiene.** Un log de la app registra sesiones, no personas. Pasar de sesión a persona es una decisión.
- **Qué faltantes hay y por qué.** Quien paga en efectivo no aparece en los cobros con tarjeta. Es un faltante estructural que nadie diseñó.
- **Quién queda afuera.** Solo se observa a quien usa el sistema. La cobertura la define la tecnología, no el investigador.

Los equipos que trabajan con datos transaccionales y con registros de uso de IA están en esta situación: tienen la tabla, y tienen que escribir el cuestionario que la habría producido.

# Datos personales: marco legal en Uruguay

- **Ley 18.331** (2008), Protección de Datos Personales y Acción de Habeas Data. Reglamentada por el Decreto 414/009; modificada por la Ley 19.670 (2018), el Decreto 64/020 y la Ley 19.924 (2020). Órgano de control: URCDP.
- Alcanza a toda base de datos con información de personas identificadas o identificables, cualquiera sea su soporte y su origen: lo que se preguntó y lo que se registró sin preguntar.

Principios con consecuencia directa en el diseño:

| Principio                       | Qué exige                                                             | En el cuestionario                                                          |
|---------------------------------|-----------------------------------------------------------------------|-----------------------------------------------------------------------------|
| Finalidad                       | Declarar para qué se recogen los datos y usarlos solo para eso        | El propósito se escribe antes de la primera pregunta y no se cambia después |
| Consentimiento previo informado | Manifestación libre, expresa e inequívoca; no se infiere del silencio | Se registra que fue otorgado                                                |
| Pertinencia                     | No recoger más de lo necesario para la finalidad                      | El criterio de longitud tiene base legal                                    |
| Seguridad y reserva             | Proteger los datos y no divulgarlos                                   | Separar identificadores de respuestas                                       |
| Derechos del titular            | Acceso, rectificación, supresión                                      | Hay que poder encontrar a una persona en la base y borrarla                 |

## Datos sensibles e identificación

**Datos sensibles** (art. 18): origen racial o étnico, preferencias políticas, convicciones religiosas o morales, afiliación sindical, salud, vida sexual. Solo se recogen con consentimiento expreso y por escrito, y con justificación.

Si una pregunta cae en esa lista, la pregunta que corresponde es si hace falta.

### Identificación:

- id es un número correlativo, no la cédula ni el correo.
- Si hay que volver a contactar a la persona, los datos de contacto van en una tabla separada, vinculada por id, con acceso restringido.
- Una tabla sin nombres puede seguir identificando: año de carrera, alquiler exacto y fuente de ingresos “Otro: trabajos freelance” pueden bastar para reconocer a alguien en una facultad chica. Anonimizar es más que borrar una columna.

La aplicación a un caso concreto requiere asesoramiento jurídico; lo que corresponde al diseñador de la encuesta es saber que estas obligaciones existen antes de salir a campo.

# Una pregunta es una medición

**Operacionalización:** el camino desde lo que se quiere saber hasta la columna.

concepto → dimensión → indicador → pregunta → variable

En el ejemplo:

| Concepto            | Dimensión            | Indicador                    | Pregunta | Variable         |
|---------------------|----------------------|------------------------------|----------|------------------|
| Situación económica | Percepción subjetiva | Autoevaluación 1-5           | P10      | situacion        |
| Situación económica | Gasto efectivo       | Monto en comida, 30 días     | P5       | gasto_comida     |
| Situación económica | Gasto efectivo       | Monto en transporte, 30 días | P6       | gasto_transporte |

Un concepto suele necesitar varias columnas. Una columna nunca es el concepto: es un indicador de una de sus dimensiones.

“Diseñar la tabla antes que el formulario” es esto: decidir qué indicadores se necesitan antes de escribir cómo se preguntan.

# Niveles de medición

Stevens (1946) distingue cuatro niveles según qué operaciones tienen sentido sobre los valores:

| Nivel     | Qué se puede hacer                        | Ejemplo                    | En la tabla            |
|-----------|-------------------------------------------|----------------------------|------------------------|
| Nominal   | Distinguir categorías                     | fuelle de ingresos         | fuelle_ingreso         |
| Ordinal   | Ordenarlas                                | año de carrera, escala 1-5 | anio, situacion        |
| Intervalo | Medir distancias; el cero es convencional | temperatura en °C          | (no hay en el ejemplo) |
| Razón     | Distancias y cocientes; el cero es real   | pesos gastados             | gasto_comida           |

- Cada nivel permite lo del anterior y algo más.
- El diseño de la pregunta fija el nivel. Después no se puede subir: de tramos no se recupera el monto.
- Sí se puede bajar: de gasto\_comida se construyen tramos cuando haga falta.
- Promediar una escala 1-5 es tratar una ordinal como de intervalo. Se hace con frecuencia; lo que no se hace es sin declararlo.

## Validez y confiabilidad

Dos propiedades de una pregunta como instrumento de medición:

- **Validez:** mide lo que dice medir. *¿Está conforme con lo que gasta en comida y en transporte?* no mide ninguna de las dos cosas por separado.
- **Confiabilidad:** mide lo mismo cada vez que se aplica. *¿Cuánto gasta en transporte?* sin período de referencia recibe respuestas distintas de la misma persona según el día.

La sección de redacción que sigue es una lista de formas conocidas de perder validez o confiabilidad.

# Fuentes de error

Marco de error total de encuesta (Groves et al. 2009). Cuatro fuentes, en el orden en que aparecen:

| Fuente       | Qué es                                                                | Dónde se controla            |
|--------------|-----------------------------------------------------------------------|------------------------------|
| Cobertura    | La lista de la que se saca la muestra no contiene a toda la población | Marco muestral               |
| Muestreo     | Se observa una parte, no el todo                                      | Diseño muestral              |
| No respuesta | Personas seleccionadas que no contestan, o ítems que quedan en blanco | Longitud, orden, redacción   |
| Medición     | La respuesta registrada no coincide con el valor verdadero            | Redacción, opciones, escalas |

Este bloque trabaja sobre las dos últimas. Cobertura y muestreo quedan para otra clase.

# Unidades

- **Población:** a quién se quiere describir.
- **Unidad de análisis:** sobre qué se hacen afirmaciones (una fila de la tabla).
- **Unidad de respuesta:** quién contesta el cuestionario.

En el ejemplo las tres coinciden: estudiantes de la facultad, un estudiante por fila, contesta el propio estudiante.

No siempre es así. En una encuesta de gasto de hogares la unidad de análisis es el hogar y responde un informante; en una encuesta a empresas responde una persona por la organización. Cuando no coinciden, el cuestionario tiene que decir explícitamente por quién se está respondiendo.

## **Tipos de pregunta y variable que generan**

---

## Opción única, sin orden

| P9. ¿Cuál es su principal fuente de ingresos? ☐ Familia ☐ Trabajo ☐ Beca ☐ Ahorros ☐ Otro

- Una columna.
- Variable **categorica nominal**: las categorías no se ordenan.
- Se guarda como texto o como código numérico con etiqueta.

## Opción única, con orden

| P1. ¿En qué año de la carrera está? ☐ 1.º ☐ 2.º ☐ 3.º ☐ 4.º ☐ 5.º o más

- Una columna.
- Variable **ordinal**: hay orden, pero la distancia entre categorías no está definida.
- El orden debe quedar registrado explícitamente (no se infiere del texto).

## Sí / No

| P2. ¿Vive en la casa familiar? ☐ Sí ☐ No

- Una columna.
- Variable **binaria**. Es una nominal de dos categorías; conviene almacenarla como lógica (TRUE/FALSE) o como 0/1.

## Escala de valoración

| P10. ¿Cómo describiría su situación económica en los últimos 30 días? 1 Muy ajustada · 2 · 3 · 4 · 5 Muy holgada

- Una columna.
- Variable **ordinal**. Que los valores sean números no la vuelve cuantitativa.
- Tratarla como numérica (promediar, por ejemplo) es una decisión analítica que se toma después y se declara. No es una propiedad del dato.

## Numérica directa

| P5. ¿Cuánto gastó en comida fuera de casa en los últimos 30 días? \$ \_\_\_\_

- Una columna.
- Variable **cuantitativa** (continua; sería discreta para una cantidad de veces).
- Es la que más información conserva. El costo: preguntas difíciles de recordar o sensibles bajan la tasa de respuesta.

## Numérica por tramos

| P6. ¿Cuánto gastó en transporte en los últimos 30 días? ☐ Nada ☐ Hasta \$1.000 ☐ \$1.001 a \$3.000 ☐ \$3.001 a \$6.000 ☐ Más de \$6.000

- Una columna, **ordinal**.
- Se pierde la posibilidad de calcular promedios o de recortar tramos distintos después.
- Se gana tasa de respuesta. Es un intercambio que se decide antes de salir a campo, porque no se puede deshacer.

P5 y P6 preguntan lo mismo (un monto) con dos diseños distintos. Ninguno es correcto en general.

# Selección múltiple

P7. ¿En cuáles de estos rubros tuvo algún gasto en los últimos 30 días? ☐ Materiales de estudio ☐ Salidas ☐ Ropa ☐ Suscripciones digitales ☐ Salud

No genera una variable. Genera una columna binaria por opción:

| id | rubro_materiales | rubro_salidas | rubro_ropa | rubro_suscripciones | rubro_salud |
|----|------------------|---------------|------------|---------------------|-------------|
| 1  | 1                | 1             | 0          | 1                   | 0           |
| 2  | 0                | 1             | 1          | 1                   | 0           |

Guardar la respuesta como un solo texto ("Salidas; Ropa; Suscripciones") es el error más frecuente en encuestas armadas sin pensar la tabla.

## Pregunta abierta

| P11. ¿Qué gasto le resulta más difícil de controlar? \_\_\_\_\_

- Una columna de **texto**.
- No se analiza directamente: requiere codificación posterior (leer, agrupar, asignar categorías). Es la pregunta más cara de procesar.
- Se justifica cuando no se conocen las categorías de antemano o cuando se quiere el lenguaje del respondente.

# Resumen

| Formato de pregunta               | Columnas | Tipo de variable    | En el ejemplo |
|-----------------------------------|----------|---------------------|---------------|
| Opción única sin orden            | 1        | Nominal             | P9            |
| Opción única con orden            | 1        | Ordinal             | P1, P4, P8    |
| Sí / No                           | 1        | Binaria             | P2            |
| Escala 1-5                        | 1        | Ordinal             | P10           |
| Número                            | 1        | Cuantitativa        | P3, P5        |
| Tramos                            | 1        | Ordinal             | P6            |
| Selección múltiple con k opciones | k        | Binarias            | P7            |
| Abierta                           | 1        | Texto (a codificar) | P11           |

Once preguntas, diecisiete columnas.

## Redacción de preguntas

---

## Una idea por pregunta

| ¿Cree que la comida de la facultad es cara y de mala calidad?

Dos preguntas en una. Quien la considera cara pero de buena calidad no tiene respuesta.

Cada pregunta mide una sola cosa. Si aparece una “y”, revisar.

## Lenguaje neutro

| ¿No cree que debería ahorrar más?

Induce la respuesta y contiene una negación (responder “no” es ambiguo).

Formulación neutra: *¿Lleva registro de sus gastos?* o *¿Cómo describiría su situación económica?*

## Período de referencia explícito

| ¿Cuánto gasta en transporte?

¿Por semana, por mes, en un mes típico, en el último mes? Cada persona responderá algo distinto.

*¿Cuánto gastó en transporte en los últimos 30 días?*

“Los últimos 30 días” y “un mes típico” no son equivalentes: uno pide recordar, el otro pide estimar. Se elige uno y se sostiene en todo el cuestionario.

## Categorías exhaustivas y excluyentes

Alquiler mensual: ☐ Hasta \$8.000 ☐ \$8.000 a \$12.000 ☐ \$12.000 a \$20.000

- No excluyentes: 8.000 y 12.000 caen en dos tramos.
- No exhaustivas: más de 20.000 no tiene opción.

Toda respuesta posible debe tener exactamente una casilla.

## Selección múltiple disfrazada

| ¿De dónde recibe ingresos? ☐ Familia ☐ Trabajo ☐ Ambos ☐ Otro

“Ambos” delata que la pregunta admite más de una respuesta. Hay dos salidas:

- Selección múltiple: una columna binaria por fuente.
- Opción única con la palabra *principal*: *¿Cuál es su principal fuente de ingresos?* (es lo que hace P9).

# Opciones de respuesta

---

## Escalas

- **Cantidad de puntos:** 4 obliga a tomar posición; 5 permite un punto neutro. Ninguna es correcta en general; se decide y se mantiene igual en todo el cuestionario.
- **Etiquetas:** etiquetar solo los extremos (1 = Muy ajustada, 5 = Muy holgada) o todos los puntos. Etiquetar todos reduce interpretaciones distintas.
- **Dirección:** mantener siempre el mismo sentido (mayor valor = mejor situación) para no confundir al respondente ni al analista.

## “Otro (especifique)” y “No sabe / No contesta”

- **Otro (especifique)** genera dos columnas: la categoría Otro en fuente\_ingreso y un campo de texto fuente\_otro. Si muchas respuestas caen en “Otro”, faltó una categoría.
- **No sabe / No contesta** es una decisión de diseño. Si se ofrece, hay que definir cómo se codifica y distinguirla de la no respuesta (dejar en blanco).

## Orden, filtros y longitud

---

## Orden

- De lo general a lo específico.
- Preguntas sensibles (montos de ingreso, situación económica) al final: si la persona abandona, ya respondió el resto.
- Las primeras preguntas deben ser fáciles y claramente relacionadas con el tema anunciado.

En el ejemplo: el perfil va primero, los montos de gasto en el medio, ingresos y percepción al final.

## Preguntas filtro

| P2. ¿Vive en la casa familiar? ☐ Sí ☐ No → si Sí, pasar a P4 P3. ¿Cuánto paga de alquiler por mes? \$ \_\_\_\_

Quien responde “Sí” en P2 no tiene P3. Esa celda queda vacía **por diseño**.

Son **faltantes estructurales**. No son lo mismo que la **no respuesta** (la persona debía contestar y no lo hizo). El libro de códigos debe distinguirlos.

## Longitud

Cada pregunta tiene un costo: tiempo del respondente y tasa de abandono.

Criterio para conservar una pregunta: la columna que genera se usa en algún análisis previsto. Si no se sabe para qué se va a usar, se elimina.

# Libro de códigos

---

## Qué es

El diccionario de variables se escribe **antes** de salir a campo, no después. Es el mismo diccionario del Práctico A y lo que SPSS guarda como metadatos.

| Variable         | Etiqueta                              | Tipo         | Valores                                                       | Faltante                             |
|------------------|---------------------------------------|--------------|---------------------------------------------------------------|--------------------------------------|
| id               | Identificador                         | entero       | 1, 2, ...                                                     | no admite                            |
| anio             | Año de la carrera                     | ordinal      | 1 < 2 < 3 < 4 < 5+                                            | NA                                   |
| vive_familia     | Vive en la casa familiar              | binaria      | TRUE, FALSE                                                   | NA                                   |
| alquiler         | Alquiler mensual (pesos)              | cuantitativa | $\geq 0$                                                      | NA si vive_familia = TRUE            |
| trabajo          | Situación laboral                     | ordinal      | No < Menos de 20 h < 20 h o más                               | NA                                   |
| gasto_comida     | Comida fuera de casa, 30 días (pesos) | cuantitativa | $\geq 0$                                                      | NA                                   |
| gasto_transporte | Transporte, 30 días                   | ordinal      | Nada < Hasta 1.000 < 1.001-3.000 < 3.001-6.000 < Más de 6.000 | NA                                   |
| rubro_* (5)      | Tuvo gasto en el rubro                | binaria      | 0, 1                                                          | NA                                   |
| registro         | Lleva registro de gastos              | ordinal      | Nunca < A veces < Siempre                                     | NA                                   |
| fuentes_ingreso  | Principal fuente de ingresos          | nominal      | Familia, Trabajo, Beca, Ahorros, Otro                         | NA                                   |
| fuentes_otro     | Otra fuente (texto)                   | texto        | libre                                                         | vacío si fuentes_ingreso $\neq$ Otro |
| situacion        | Situación económica, 30 días          | ordinal      | 1 < 2 < 3 < 4 < 5                                             | NA                                   |
| gasto_dificil    | Gasto difícil de controlar (abierto)  | texto        | libre                                                         | vacío                                |

## Convenciones de nombres

- Minúsculas, sin espacios ni tildes: `gasto_comida`, no `Gasto en comida`.
- Prefijo común para las binarias de una misma selección múltiple: `rubro_materiales`, `rubro_salidas`, `rubro_ropa`, ...
- El nombre describe el contenido, no la posición: `alquiler`, no `p3`.

# Cómo queda la tabla

---

# Lectura y tipos

[pestañas R / Python]

## R

```
library(tidyverse)

encuesta <- read_csv("encuesta_gasto.csv")
glimpse(encuesta)
```

```
Rows: 4
Columns: 17
$ id          <dbl> 1, 2, 3, 4
$ anio        <dbl> 2, 4, 1, 3
$ vive_familia <chr> "Sí", "No", "Sí", "No"
$ alquiler    <dbl> NA, 12000, NA, 9000
$ trabajo     <chr> "No", "Sí, 20 h o más", "No", "Sí, menos de 20 h"
$ gasto_comida <dbl> 4500, 8200, NA, 6000
$ gasto_transporte <chr> "1.001 a 3.000", "Más de 6.000", "Hasta 1.000", "Nada"
$ rubro_materiales <dbl> 1, 0, 1, 0
$ rubro_salidas <dbl> 1, 1, 0, 1
$ rubro_ropa    <dbl> 0, 1, 0, 0
$ rubro_suscripciones <dbl> 1, 1, 0, 1
$ rubro_salud   <dbl> 0, 0, 0, 1
$ registro     <chr> "A veces", "Siempre", "Nunca", "A veces"
$ fuente_ingreso <chr> "Familia", "Trabajo", "Familia", "Otro"
$ fuente_otro   <chr> NA, NA, NA, "trabajos freelance"
$ situacion     <dbl> 3, 2, 4, 3
$ gasto_dificil <chr> "salidas", "delivery", NA, "suscripciones"
```

## Python

```
import pandas as pd

encuesta = pd.read_csv("encuesta_gasto.csv")
encuesta.dtypes
```

```
id          int64
anio        int64
vive_familia object
alquiler    float64
trabajo     object
gasto_comida float64
gasto_transporte object
rubro_materiales int64
rubro_salidas int64
```

```
rubro_ropa          int64
rubro_suscripciones int64
rubro_salud         int64
registro            object
fuente_ingreso       object
fuente_otro          object
situacion           int64
gasto_dificil        object
dtype: object
```

Tres faltantes de naturaleza distinta: alquiler en los respondentes 1 y 3 (filtro), gasto\_comida en el 3 (no respuesta), fuente\_otro en 1, 2 y 3 (no aplica). La tabla no los distingue; el libro de códigos sí.

# Declarar los tipos

[pestañas R / Python]

## R

```
encuesta <- encuesta |>
  mutate(
    anio = factor(anio, levels = 1:5, ordered = TRUE),
    vive_familia = vive_familia == "Sí",
    trabajo = factor(trabajo,
      levels = c("No", "Sí, menos de 20 h", "Sí, 20 h o más"), ordered = TRUE),
    gasto_transporte = factor(gasto_transporte,
      levels = c("Nada", "Hasta 1.000", "1.001 a 3.000",
        "3.001 a 6.000", "Más de 6.000"), ordered = TRUE),
    registro = factor(registro,
      levels = c("Nunca", "A veces", "Siempre"), ordered = TRUE),
    fuente_ingreso = factor(fuente_ingreso),
    situacion = factor(situacion, levels = 1:5, ordered = TRUE)
  )
```

```
$ anio          <ord> 2, 4, 1, 3
$ vive_familia  <lgl> TRUE, FALSE, TRUE, FALSE
$ trabajo       <ord> No, Sí, 20 h o más, No, Sí, menos de 20 h
$ gasto_transporte <ord> 1.001 a 3.000, Más de 6.000, Hasta 1.000, Nada
$ registro      <ord> A veces, Siempre, Nunca, A veces
$ fuente_ingreso <fct> Familia, Trabajo, Familia, Otro
$ situacion     <ord> 3, 2, 4, 3
```

## Python

```
encuesta["anio"] = pd.Categorical(encuesta["anio"],
  categories=[1, 2, 3, 4, 5], ordered=True)
encuesta["vive_familia"] = encuesta["vive_familia"] == "Sí"
encuesta["trabajo"] = pd.Categorical(encuesta["trabajo"],
  categories=["No", "Sí, menos de 20 h", "Sí, 20 h o más"], ordered=True)
encuesta["gasto_transporte"] = pd.Categorical(encuesta["gasto_transporte"],
  categories=["Nada", "Hasta 1.000", "1.001 a 3.000",
    "3.001 a 6.000", "Más de 6.000"], ordered=True)
encuesta["registro"] = pd.Categorical(encuesta["registro"],
  categories=["Nunca", "A veces", "Siempre"], ordered=True)
encuesta["fuente_ingreso"] = encuesta["fuente_ingreso"].astype("category")
encuesta["situacion"] = pd.Categorical(encuesta["situacion"],
  categories=[1, 2, 3, 4, 5], ordered=True)
```

```
anio          category
vive_familia  bool
```

|                  |          |
|------------------|----------|
| trabajo          | category |
| gasto_transporte | category |
| registro         | category |
| fuentes_ingreso  | category |
| situacion        | category |

El orden de las categorías se declara en el código porque no está en el archivo. Esa declaración sale del libro de códigos.

# Ejercicio

---

# De la tabla al cuestionario

Se quiere obtener esta tabla a partir de una encuesta a clientes de la cafetería de la facultad. Escribir el cuestionario que la produce: texto de cada pregunta, opciones de respuesta, orden y filtros.

| Variable                                        | Tipo         | Valores                                            | Faltante                 |
|-------------------------------------------------|--------------|----------------------------------------------------|--------------------------|
| id                                              | entero       | 1, 2, ...                                          | no admite                |
| frecuencia                                      | ordinal      | Nunca < 1 a 3 veces < 4 a 8 veces < Más de 8 veces | NA                       |
| prod_cafe, prod_comida, prod_frias, prod_otros  | binaria (x4) | 0, 1                                               | NA si frecuencia = Nunca |
| atencion                                        | ordinal      | 1 < 2 < 3 < 4 < 5                                  | NA si frecuencia = Nunca |
| pago_efectivo, pago_tarjeta, pago_transferencia | binaria (x3) | 0, 1                                               | NA si frecuencia = Nunca |
| estudiante                                      | binaria      | TRUE, FALSE                                        | NA                       |
| edad                                            | cuantitativa | años                                               | NA                       |
| mejora                                          | texto        | libre                                              | vacío                    |

## Qué se verifica

- Toda pregunta tiene período de referencia.
- Hay un filtro después de `frecuencia` y está indicado a dónde saltar.
- `prod_*` y `pago_*` salen de preguntas de selección múltiple, no de opción única con “ambos”.
- `atencion` tiene los extremos etiquetados y la misma dirección que el resto del cuestionario.
- `edad` está al final.
- Cuántas preguntas se necesitan para producir trece columnas.

## Cuestionario de referencia

1. ¿Con qué frecuencia compró en la cafetería en los últimos 30 días? ☐ Nunca ☐ 1 a 3 veces ☐ 4 a 8 veces ☐ Más de 8 veces → si Nunca, pasar a P5
2. ¿Qué productos compró? (marque todas) ☐ Café ☐ Comida ☐ Bebidas frías ☐ Otros
3. ¿Cómo calificaría la atención recibida? 1 Muy mala · 2 · 3 · 4 · 5 Muy buena
4. ¿Con qué medios pagó? (marque todas) ☐ Efectivo ☐ Tarjeta ☐ Transferencia
5. ¿Es estudiante de esta facultad? ☐ Sí ☐ No
6. ¿Qué mejoraría del servicio? \_\_\_\_\_
7. ¿Cuántos años tiene? \_\_\_\_

Siete preguntas, trece columnas.

## Para la bitácora

Seis preguntas con problemas. Para cada una: identificar el problema, reescribirla y decir qué tipo de variable produce (y cuántas columnas).

1. ¿Está conforme con lo que gasta en comida y en transporte?
2. ¿No le parece que gasta demasiado en salidas?
3. ¿Cuánto gastó últimamente en ropa?
4. Gasto en transporte: ☐ \$0 a \$1.000 ☐ \$1.000 a \$3.000 ☐ \$3.000 a \$6.000
5. ¿Cómo paga sus gastos? ☐ Efectivo ☐ Tarjeta ☐ Ambos ☐ Transferencia
6. (Primera pregunta del cuestionario) ¿Cuál es el ingreso mensual exacto de su hogar?

## Soluciones

1. Doble cañón. Separar en dos preguntas; cada una ordinal (escala 1-5).
2. Inducida y con negación. *¿Cuánto gastó en salidas en los últimos 30 días?* Cuantitativa, o tramos (ordinal).
3. Sin período de referencia. *¿Cuánto gastó en ropa en los últimos 30 días?* Cuantitativa.
4. Tramos no excluyentes ni exhaustivos. Nada / Hasta 1.000 / 1.001-3.000 / 3.001-6.000 / Más de 6.000. Ordinal.
5. Selección múltiple disfrazada. Una binaria por medio de pago: pago\_efectivo, pago\_tarjeta, pago\_transferencia.
6. Pregunta sensible al inicio y con precisión innecesaria. Mover al final y ofrecer tramos. Ordinal.