

Pauta de trabajo en equipo

Introducción a la Ciencia de Datos — Facultad de Ciencias Empresariales y
Economía, Universidad de Montevideo

Contenido

1. El proceso	2
2. Organización de carpetas	3
3. Entregables finales	3
4. Paso 1 — Importar los datos crudos	3
5. Paso 2 — Perfilar el dato crudo	3
6. Paso 3 — Ordenar y limpiar	4
7. Paso 4 — Unir tablas	4
8. Paso 5 — Generar nueva información	5
9. Paso 6 — Explorar: visualizar y modelar	5
10. Paso 7 — Comunicar	6
11. El peso de cada paso cambia según el equipo	6
12. Evaluación	6
13. Calendario	7

1. El proceso




Figura 1: Esquema del proceso completo. Tomado de *R para Ciencia de Datos*, Wickham, Çetinkaya-Rundel y Grolemund.

El trabajo recorre siete pasos básicos de la ciencia de datos. El informe final tiene una sección por paso, en este orden y con estos títulos.

Paso		Correspondencia con el esquema
1	Importar los datos crudos	Importar
2	Perfilar el dato crudo	<i>adicional, no aparece en el esquema</i>
3	Ordenar y limpiar	Ordenar
4	Unir tablas	Transformar
5	Generar nueva información	Transformar
6	Explorar: visualizar y modelar	Visualizar □ Modelar
7	Comunicar	Comunicar

Dos observaciones sobre el esquema.

El perfilado no está en el diagrama, y es el paso que falta. Antes de ordenar y limpiar hay que saber qué se tiene entre manos: cuántas filas, qué tipos, cuántos faltantes, qué valores toma cada variable, qué se repite. El perfilado no modifica nada; es el diagnóstico que justifica todo lo que se hace después. Sin él, la limpieza es a ciegas.

Los pasos 5 y 6 son un ciclo, no una secuencia. En el diagrama, transformar, visualizar y modelar están dentro de un bucle. Se explora, aparece algo raro, se vuelve a transformar, se vuelve a explorar. El informe se escribe en orden lineal porque hay que leerlo, pero el trabajo no fue lineal y conviene que el informe lo diga.

La caja exterior, Programa, no es un paso: atraviesa todos. Todo lo que se hace del paso 1 al 7 queda escrito en código ejecutable. No hay pasos manuales sin registro.

Ningún paso se omite. Un paso que en el trabajo del equipo no tuvo dificultad se resuelve en un párrafo que explica por qué. Ese párrafo también se evalúa.

2. Organización de carpetas

Se sugiere organizar las carpetas en: - código - datos/ o data, la cual separar en: - datos crudos - datos finales - resultados

3. Entregables finales

- trabajo finalizado en github al 19/11
- documento o informe: una presentación o un informe que muestre todos los pasos.

4. Paso 1 — Importar los datos crudos

Qué se hace. Traer los datos al entorno de trabajo tal como los entrega la fuente, sin modificarlos.

Qué se documenta.

- De dónde salieron: organismo, plataforma, competencia, o el propio equipo si los generó.
- Cómo se obtuvieron: descarga, interfaz de programación, extracción, encuesta, registro.
- Cuándo se obtuvieron y en qué formato llegaron.
- Los problemas de la importación misma: codificación de caracteres, separador decimal, filas de encabezado, hojas múltiples, tipos que el lector adivinó mal.

Qué se entrega. Los archivos originales guardados sin modificar, en una carpeta aparte. El archivo crudo no se edita nunca.

Si el equipo generó sus propios datos, este paso incluye el instrumento completo, cómo se aplicó, a quiénes, y cuántos no respondieron.

5. Paso 2 — Perfilar el dato crudo

Qué se hace. Describir lo que se importó, sin cambiarlo todavía. Es un diagnóstico, no una intervención.

Qué se documenta.

- Dimensiones: filas y columnas de cada tabla importada.
- Qué representa una fila. Si no es evidente, se averigua antes de seguir.
- Por cada variable: tipo, cantidad de valores distintos, cantidad de faltantes, y mínimo y máximo si es numérica.
- Cómo está codificado el faltante en el original: celda vacía, cero, -, 999, sin dato, texto libre.

- Categorías que aparecen escritas de más de una forma.
- Valores fuera de rango o imposibles.
- Filas repetidas, y con qué criterio se decidió que dos filas son la misma observación.
- Si hay más de una tabla, si la clave que las vincularía identifica de manera única las filas de cada una.

Qué se entrega. Una tabla de perfilado con una fila por variable. **De ella sale la lista de problemas a resolver en el paso 3:** cada decisión de limpieza debe poder rastrearse hasta un hallazgo del perfilado.

El perfilado se repite después de limpiar, sobre la tabla final, como verificación. Esa segunda tabla va en el informe junto a la primera.

6. Paso 3 — Ordenar y limpiar

Son dos cosas distintas y se documentan por separado. **Ordenar** es la estructura de la tabla; **limpiar** es el contenido de las celdas. Una tabla puede estar ordenada y sucia, o limpia y desordenada.

Ordenar. Llevar los datos a una tabla ordenada: una fila por observación, una columna por variable, un valor por celda. Se documenta qué estaba desordenado y cómo se resolvió: columnas que en realidad eran valores de una variable, dos variables metidas en una columna, encabezados ocupando filas, varias tablas dentro de una planilla.

Limpiar. Corregir el contenido, resolviendo los problemas listados en el perfilado. Se documenta:

- Conversiones de tipo, y qué pasó con los valores que no se pudieron convertir.
- Qué se hizo con los faltantes de cada variable y por qué.
- Duplicados eliminados.
- Categorías unificadas, unidades homogeneizadas, valores imposibles corregidos o marcados.

Qué se entrega. El conteo de filas antes y después, con la explicación de cada fila perdida.

7. Paso 4 — Unir tablas

Qué se hace. Combinar dos o más tablas en una sola, cuando corresponde.

Qué se documenta.

- Qué tablas se unieron y qué aporta cada una.
- Cuál es la clave de unión, y si identifica de manera única las filas de cada tabla — dato que viene del perfilado.

- Qué tipo de unión se hizo y por qué esa.
- Cuántas filas quedaron sin correspondencia de cada lado y qué se hizo con ellas.
Este número se reporta siempre, aunque sea cero.
- Si la unión cambió la cantidad de filas de manera inesperada, la explicación.

Si el equipo no unió tablas, el paso es un párrafo que dice que se trabajó sobre una única tabla y por qué no hizo falta más.

8. Paso 5 — Generar nueva información

Qué se hace. Producir datos que no estaban en la fuente: variables nuevas, agregaciones, indicadores.

Qué se documenta.

- Variables creadas: cómo se calcula cada una, a partir de qué y qué mide.
- Agregaciones: por qué grupos, con qué función de resumen, y cuántas observaciones tiene cada grupo.
- Transformaciones de escala: per cápita, porcentaje, tasa, logaritmo, deflactación, categorización de una variable continua — cada una con su justificación, y con el criterio de los cortes si se categorizó.

Qué se entrega. Cada variable nueva figura en el diccionario de variables, con su fórmula.

Este paso y el siguiente se recorren varias veces. Es esperable que la exploración obligue a volver acá y crear o rehacer una variable.

9. Paso 6 — Explorar: visualizar y modelar

Qué se hace. Entender el comportamiento de las variables, primero solas y después entre sí, alternando gráficos y resúmenes numéricos.

Qué se documenta.

- Distribución de cada variable relevante antes de relacionarla con otras: centro, dispersión, forma, valores extremos.
- Qué relaciones se exploraron entre pares de variables y cómo se midieron.
- Al menos una relación examinada en más detalle: separada por una tercera variable, o mirada en subgrupos, para ver si se mantiene.
- Los casos extremos que influyen sobre el resultado, identificados y discutidos.
- Qué se buscó y no apareció. Una relación esperada que no está es un resultado.
- Si se ajustó algún modelo: qué se calculó, sobre qué observaciones, y qué supone ese cálculo.

Qué se entrega. Los gráficos de la exploración, incluidos los que no confirmaron nada, y una descripción de las idas y vueltas entre este paso y el anterior.

10. Paso 7 — Comunicar

Qué se hace. Mostrar lo encontrado a un destinatario definido.

Qué se documenta.

- A quién está dirigido el informe y qué sabe ese lector de antemano.
- La afirmación central del trabajo, en una frase.
- Los gráficos y tablas finales, cada uno con título, ejes rotulados con unidades y fuente.
- Los límites: qué no puede afirmarse con estos datos y por qué.
- La objeción más fuerte que el propio equipo puede formular contra su afirmación central.

Qué se entrega. El informe renderizado y la presentación oral de 8 minutos.

11. El peso de cada paso cambia según el equipo

Los siete pasos son los mismos para todos, pero no cuestan lo mismo. Eso lo determinan los datos que el equipo eligió, no el tema.

Un equipo que **genera sus propios datos** dedica mucho trabajo al paso 1: armar el instrumento, aplicarlo y recoger las respuestas lleva semanas, y en cambio llega al paso 6 con pocas variables y poco que explorar.

Un equipo que **recibe un conjunto ya armado y limpio** pasa rápido por los pasos 1 a 4 y tiene que trabajar mucho más en los pasos 5 y 6: ahí está su dificultad, porque el dato no le plantea ningún problema y la exigencia se traslada a qué construye y qué encuentra con él.

Un equipo que **trabaja con varias fuentes** carga el paso 4. Uno con **muchos faltantes o registros sucios**, los pasos 2 y 3. Uno con **datos que no son tablas**, los pasos 1 y 3.

11.0.1. Declaración de énfasis

En el Control 1 cada equipo entrega media página con la pregunta, qué representa una fila de su tabla final, los dos pasos donde va a estar el grueso de su trabajo, y la razón en términos de sus datos.

Se discute y se aprueba. A partir de ahí es el criterio con el que se evalúa a ese equipo. Puede corregirse durante el semestre si el equipo descubre que la dificultad estaba en otro lado; el cambio, documentado, suma.

12. Evaluación

Criterio	Peso
Los dos pasos declarados como énfasis	35 %
Los cinco pasos restantes, resueltos y documentados	25 %
Reproducibilidad: del crudo a la tabla final sin intervención del equipo	15 %
Límites del propio trabajo	15 %
Comunicación	10 %

13. Calendario

Instancia	Entrega
Presentación 1	Pasos 1 y 2 completos (datos importados y perfilados) y declaración de énfasis
Presentación 2	Tabla final construida (pasos 3 a 5), segundo perfilado y diccionario de variables
Presentación Final 3	Exploración avanzada (paso 6)
Entrega final	Informe final y github concluido